

Clasificación

Verónica E. Arriola-Rios

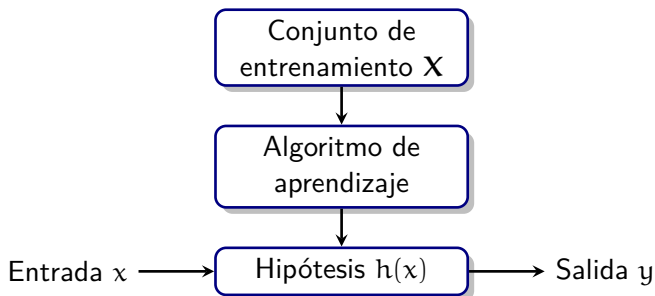
Aprendizaje de máquina

19 de febrero de 2024

Problema

- En un problema de clasificación se pretende, dadas las características de un ejemplar, identificar la clase a la cual pertenece.

Clasificación



$$h(x) : \mathbb{R}^n \rightarrow \{e | e \text{ es una etiqueta de clase}\} \quad (1)$$

Temas

- 1 Regresión logística
- 2 Función de costo
- 3 Medidas de rendimiento

Espacio de hipótesis

- Convierte las rectas en fronteras entre regiones correspondientes a clases.

$$h_{\Theta}(X) = \frac{1}{1 + e^{-\Theta^T X}} \quad (2)$$

Regresión logística

$$h_{\Theta}(X) = g(\Theta^T X) \quad (3)$$

$$g(Z) = \frac{1}{1 + e^{-Z}} \quad (4)$$

donde $g(Z)$ es la función *logística* o *sigmoide*. Obsérvese que $Z = \Theta^T X$.




Figura: Función logística.

Regresión logística multivariada (Ejemplo)

$$z = \theta_0 + \theta_1 x_1 + \theta_2 x_2 \quad (5)$$

$$h_{\Theta}(x) = g(z) \quad (6)$$

- si $z > 0$ el ejemplar es positivo.
- si $z < 0$ el ejemplar es negativo.




Figura: Problema de clasificación, ilustrado en el plano.

Regresión logística multivariada (Ejemplo)

$$z = \theta_0 + \theta_1 x_1^2 + \theta_2 x_2^2 \quad (7)$$

$$h_{\Theta}(x) = g(z) \quad (8)$$

- si $z > 0$ el ejemplar es positivo.
- si $z < 0$ el ejemplar es negativo.




Figura: Problema de clasificación, ilustrado en el plano.

Temas

- 1 Regresión logística
- 2 **Función de costo**
- 3 Medidas de rendimiento

Función de costo

- La función de error cuadrático tiene numerosos máximos y mínimos locales, por lo que es difícil de optimizar.
- Se utiliza en su lugar la entropía cruzada, que para este caso es un poco más regular.

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y \log(h_{\theta}(x)) + (1 - y) \log(1 - h_{\theta}(x))] \quad (9)$$

$$h_{\theta}(X) = \frac{1}{1 + e^{-\theta^T X}} \quad (10)$$

donde m es el número de ejemplares de entrenamiento.

- Se optimiza con algoritmos numéricos, como descenso por el gradiente.

La derivada de la hipótesis

$$\frac{\partial h}{\partial \theta_i} = -\frac{1}{(1 + e^{-\Theta^T X})^2} e^{-\Theta^T X} (-x_i) \quad (11)$$

$$= \frac{1}{1 + e^{-\Theta^T X}} \frac{e^{-\Theta^T X}}{1 + e^{-\Theta^T X}} (x_i) \quad (12)$$

$$= h_{\Theta}(X) \frac{e^{-\Theta^T X}}{1 + e^{-\Theta^T X}} (x_i) \quad (13)$$

$$= h_{\Theta}(X) \frac{-1 + 1 + e^{-\Theta^T X}}{1 + e^{-\Theta^T X}} (x_i) \quad (14)$$

$$= h_{\Theta}(X) \left(\frac{1 + e^{-\Theta^T X}}{1 + e^{-\Theta^T X}} - \frac{1}{1 + e^{-\Theta^T X}} \right) (x_i) \quad (15)$$

$$\frac{\partial h}{\partial \theta_i} = h_{\Theta}(X) (1 - h_{\Theta}(X)) x_i \quad (16)$$

Función de costo (entropía cruzada)

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{Costo}(h_{\theta}(x^{(i)}), y^{(i)}) \quad (17)$$

$$\text{Costo}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{si } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{si } y = 0 \end{cases} \quad (18)$$

$$= -y \log(h_{\theta}(x)) - (1 - y) \log(1 - h_{\theta}(x)) \quad (19)$$

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m y \log(h_{\theta}(x)) + (1 - y) \log(1 - h_{\theta}(x)) \right] \quad (20)$$

† $J(\theta)$ se elige utilizando máxima verosimilitud.

Función de costo y su derivada

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y \log(h_{\theta}(x)) + (1 - y) \log(1 - h_{\theta}(x))] \quad (21)$$

$$h_{\Theta}(X) = \frac{1}{1 + e^{-\Theta^T X}} \quad (22)$$

$$\frac{\partial J}{\partial \theta_i} = \frac{1}{m} \sum_{i=1}^m [h_{\Theta}(X) - y] x_i \quad (23)$$

Entonces, el algoritmo de descenso por el gradiente luce igual que para regresión lineal, excepto por la forma de $h_{\Theta}(X)$.

Derivada de la función de costo

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y \log(h_{\theta}(x)) + (1 - y) \log(1 - h_{\theta}(x))] \quad (24)$$

$$\frac{\partial J}{\partial \theta_i} = -\frac{1}{m} \sum_{i=1}^m \left[y \frac{\partial}{\partial \theta_i} \log(h_{\theta}(x)) + (1 - y) \frac{\partial}{\partial \theta_i} \log(1 - h_{\theta}(x)) \right] \quad (25)$$

$$= -\frac{1}{m} \sum_{i=1}^m \left[y \frac{1}{h_{\theta}(x)} \frac{\partial h}{\partial \theta_i} - (1 - y) \frac{1}{1 - h_{\theta}(x)} \frac{\partial h}{\partial \theta_i} \right] \quad (26)$$

$$(27)$$

$$= -\frac{1}{m} \sum_{i=1}^m \left[y \frac{h_{\theta}(X)(1 - h_{\theta}(X))}{h_{\theta}(x)} - (1 - y) \frac{h_{\theta}(X)(1 - h_{\theta}(X))}{1 - h_{\theta}(x)} \right] x_i \quad (28)$$

$$\frac{\partial J}{\partial \theta_i} = -\frac{1}{m} \sum_{i=1}^m [y(1 - h_{\Theta}(X)) - (1 - y)h_{\Theta}(X)] x_i \quad (29)$$

$$\frac{\partial J}{\partial \theta_i} = -\frac{1}{m} \sum_{i=1}^m \left[y - \cancel{y h_{\Theta}(X)}^0 - h_{\Theta}(X) + \cancel{y h_{\Theta}(X)}^0 \right] x_i \quad (30)$$

$$\frac{\partial J}{\partial \theta_i} = \frac{1}{m} \sum_{i=1}^m [h_{\Theta}(X) - y] x_i \quad (31)$$

En forma vectorizada:

$$\nabla J = \frac{1}{m} X^T (H_{\Theta} - Y) \quad (32)$$

Temas

- 1 Regresión logística
- 2 Función de costo
- 3 Medidas de rendimiento

Matriz de confusión binaria

- Cuando se trata de evaluar a un clasificador, la función de error se usa para entrenar, pero no necesariamente sirve para indicar si el clasificador funciona correctamente o no.
- La *matriz de confusión* contabiliza los aciertos y errores efectivos que ha cometido el clasificador sobre un conjunto de ejemplares.

Tabla: Matriz de confusión

	Predicción negativa	Predicción positiva
Casos negativos	VN	FP
Casos positivos	FN	VP

Precisión y recuperación

- En inglés se les conoce como *precision and recall*, que miden la relevancia y completez en la detección de una clase.

$$P = \frac{VP}{VP + FP} \quad (33)$$

$$R = \frac{VP}{VP + FN} \quad (34)$$

- Como resumen se utiliza la exactitud (*accuracy*)


$$A = \frac{VP + VN}{VP + VN + FP + FN} = \frac{VP + VN}{TOTAL} \quad (35)$$



- También se utiliza la media armónica de la precisión y la recuperación, conocida como F



$$F = 2 \cdot \frac{\text{precisión} \times \text{recuperación}}{\text{precisión} + \text{recuperación}} \quad (36)$$



Uno vs. todos

One-vs-all (one-vs-rest):




Class 1:  

Class 2:  


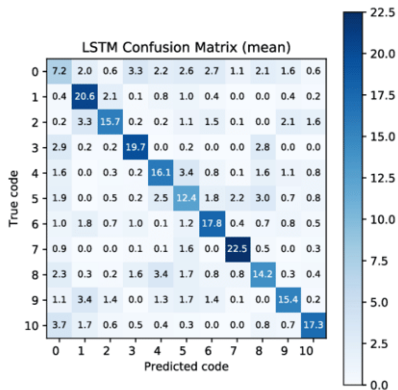
Class 3:  

$$h_{\theta}^{(i)}(x) = P(y = i|x; \theta) \quad (i = 1, 2, 3)$$



Andrew Ng

Matriz de confusión multiclase



Referencias I

Scikit Docs Precision-Recall Curves